

DRL Portfolio

Un agent de trading par apprentissage par renforcement profond :
mon cheminement, mes erreurs, mes corrections, mes résultats

Rapport pédagogique — version du 3 juillet 2026

Martin Chassaing
IMT Atlantique & Université Paris Dauphine

Résumé

Ce rapport retrace la construction d'un agent de trading par *Deep Reinforcement Learning* (PPO) sur données journalières réelles, en suivant le cheminement réel du projet : ce que j'ai essayé, ce qui n'a pas fonctionné, pourquoi, et ce que chaque constat m'a poussé à faire ensuite. Sur un test set jamais vu à l'entraînement (février 2021 → décembre 2022), l'agent multi-actifs réalise +23,8 % contre -3,7 % pour le Buy & Hold (alpha +27,5 %), avec un alpha positif sur les cinq actifs testés. Mais la validation *walk-forward* (25 cellules année×actif out-of-sample) que j'ai menée ensuite relativise ce chiffre : l'agent a un profil *défensif régime-dépendant* — rendement absolu positif 4 années sur 5 et alpha fortement positif dans les marchés baissiers, mais retard net sur le B&H dans les fortes hausses. Chaque étape est reliée aux notions d'économétrie (stationnarité, GARCH, biais de look-ahead, validation out-of-sample) et de gestion de portefeuille (alpha de Jensen, Sharpe, Sortino, CVaR, drawdown). Enfin, deux stress-tests que je me suis imposés — sensibilité aux frais et ablation du kill-switch — montrent que l'essentiel de l'alpha 2022 provient de la règle de stop : un alpha de *gestion du risque* plus que de signal, distinction que j'assume et documente. Projet strictement éducatif.

Table des matières

1	Objectif et démarche	3
2	Architecture du projet	4
3	Base théorique : du RL au trading	4
3.1	Le trading comme processus de décision markovien	4
3.2	PPO en deux idées	5
3.3	Trois choix de conception — et les alternatives écartées	6
3.4	Single-agent, multi-actifs, multi-agents : ne pas confondre	7
4	Features : le pont avec l'économétrie	7
4.1	Pourquoi ma récompense est un alpha de Jensen par pas de temps	10
4.2	Métriques d'évaluation	10
5	Chronologie : ce qui ne marchait pas, ce que j'ai changé	11
5.1	Point de départ	11
5.2	Itération 1 — des tests, parce qu'un simulateur faux rend tout faux	11
5.3	Itération 2 — mon protocole d'évaluation mentait	11
5.4	Itération 3 — plus de cycles de marché	12
5.5	Itération 4 — le bug décisif : ma validation était corrompue	12
5.6	Récapitulatif chiffré	13

6 Résultats sur le split de référence	14
6.1 Test AAPL, février 2021 → décembre 2022	14
6.2 Généralisation cross-actifs	15
7 Du backtest unique au walk-forward	16
7.1 Pourquoi c'était la priorité (et pas la diffusion ou le MARL)	16
7.2 Protocole	16
7.3 Ce que j'avais prédit — et ce qui s'est passé	17
7.4 Interprétation financière : un profil, pas un alpha universel	17
7.5 Ce que ça ouvre	18
8 Stress-tests : les questions qu'un desk poserait	18
8.1 « Ton alpha survit-il à des frais réalistes ? »	18
8.2 « Que reste-t-il si j'enlève ton kill-switch ? »	18
8.3 Les questions restantes — et celle qui a depuis reçu sa mesure	19
9 Acte 3 : attaquer la dépendance de régime	19
9.1 D'abord la barre d'erreur : cinq seeds	19
9.2 Le traitement : des features de régime — et son échec instructif	20
9.3 Bilan de l'acte	21
10 Overfitting, underfitting, régimes : le diagnostic complet	22
11 Acte 4 : le générateur de scénarios — mon volet IA générative	22
11.1 Le protocole avant le modèle	23
11.2 É1 rejette mon protocole v1 — quatre leçons avant le premier modèle	23
11.3 v1 : un NO-GO qui contredit ma prédiction — dans les deux sens	24
11.4 L'expérience contrôlée qui a choisi la v2	24
11.5 Verdict v2 : NO-GO — et le vrai coupable n'était aucun des deux objectifs	24
11.6 Ce que ça ouvre	26
12 Limites honnêtes et travaux futurs	26
13 Glossaire minute	27
14 Reproduire les résultats	30
A Annexe mathématique	30
A.1 Du policy gradient à l'avantage	30
A.2 Estimation de l'avantage : GAE	31
A.3 La perte PPO complète	31
A.4 Le processus d'Ornstein-Uhlenbeck en détail	31
B Compléments théoriques : les ponts avec mes cours	32
B.1 CAPM et alpha de Jensen : d'où vient ma récompense	32
B.2 Markowitz, frontière efficiente et ratio de Sharpe	32
B.3 GARCH : modéliser le regroupement de volatilité	33
B.4 Équation de Bellman : le socle de la fonction de valeur	33

1 Objectif et démarche

Je suis parti d’une question simple : *un agent d’apprentissage par renforcement peut-il apprendre à battre une stratégie passive (Buy & Hold) sur données réelles, une fois les frais de transaction pris en compte ?*

Pourquoi cette question n’est pas naïve : l’efficience des marchés. Mon agent n’observe que des transformations de prix passés (rendements, volatilité, momentum...). Or l’hypothèse d’efficience des marchés dans sa **forme faible** (Fama, 1970) affirme précisément que les prix intègrent déjà toute l’information contenue dans leur propre historique : aucune stratégie fondée sur les prix passés ne devrait battre durablement le marché *après coûts*. Ce projet est donc, littéralement, **un test empirique de l’efficience faible** sur mon échantillon. Et son résultat final est cohérent avec la littérature : pas de machine à cash, mais un edge modeste, défensif, dépendant du régime et majoritairement porté par une règle de risque — le même genre de « violation limite » que les anomalies documentées (momentum de Jegadeesh-Titman en tête). Savoir formuler le projet ainsi change tout : je ne prétends pas avoir réfuté Fama, je mesure *où* et *de combien* l’hypothèse craque sur cinq actifs et treize ans.

Pourquoi du RL, et pas de la prédiction supervisée ? L’alternative évidente serait un modèle supervisé qui prédit le rendement de demain, suivi d’une règle de trading. Deux raisons m’ont fait préférer le RL : (1) la décision de trading est *séquentielle et porteuse d’état* — ma position d’aujourd’hui conditionne mes frais de demain (fermer puis rouvrir coûte deux fois) : optimiser la qualité de prédiction n’optimise pas la politique de trading, qui doit arbitrer signal contre coûts de changement de position ; (2) mon objectif réel — l’alpha net de frais sous contrainte de drawdown — s’écrit naturellement comme une fonction de récompense, pas comme une erreur quadratique de prévision. Le RL optimise directement ce que je veux maximiser ; le supervisé optimise un substitut.

À la fin du parcours, ma réponse tient en trois temps, et c’est ce cheminement que ce rapport documente :

1. mes premiers résultats semblaient bons mais étaient **invalides** — pas parce que le modèle était mauvais, mais parce que mon protocole d’évaluation était faux (observations non normalisées, frais incohérents, validation corrompue) ;
2. une fois le protocole corrigé et le modèle réentraîné, l’agent **bat nettement le B&H** sur mon split de test, et généralise sur cinq actifs ;
3. la validation walk-forward m’a ensuite appris que ce résultat était **partiellement un artefact de la période de test** : mon agent est défensif, brillant en marché baissier, à la traîne dans les fortes hausses.

La leçon transversale : en finance quantitative, *la qualité d’une conclusion vaut celle du protocole qui la produit*. J’ai passé plus de temps à fiabiliser l’évaluation qu’à optimiser le modèle — et c’est l’évaluation qui a tout changé.

Ma méthode, en cinq règles. Tout le rapport applique la même discipline ; autant l’énoncer une fois pour toutes :

1. **Fiabiliser avant d’optimiser** : un simulateur ou un protocole faux rend toute optimisation illisible — les tests et les corrections passent avant les hyperparamètres.
2. **Une prédiction écrite avant chaque expérience** : elle force à réfléchir avant de calculer, et une prédiction fausse enseigne plus qu’une juste (les miennes sont documentées, y compris les fausses).
3. **Un levier à la fois** : quand plusieurs choses changent ensemble, une ablation contrôlée isole l’effet causal (tableaux 3 et 8).

4. **Aucune conclusion sans barre d'erreur** : un chiffre unique est un tirage ; la bande inter-seeds (section 9.1) est le juge de paix.
5. **Chercher à se falsifier** : walk-forward, stress-tests, ablations — si le résultat survit à mes propres attaques, alors seulement il mérite d'être présenté.

2 Architecture du projet

Fichier	Rôle	Contenu
<code>data_loader.py</code>	Données	Téléchargement yfinance, feature engineering, normalisation <i>fittée sur le train uniquement</i> , split temporel 70/15/15, pipeline multi-actifs avec segments.
<code>environment.py</code>	Simulation	Environnement Gymnasium : 4 actions (Hold/Long/Flat/Short), comptabilité exacte des frais, kill-switch drawdown, épisodes confinés par actif.
<code>train.py</code>	Entraînement	PPO (Stable-Baselines3), 4 environnements parallèles, normalisation des observations (<code>VecNormalize</code>), sélection du meilleur modèle sur la validation.
<code>evaluate.py</code>	Évaluation	Protocole déterministe sur split complet, robustesse sur sous-fenêtres, Sharpe/Sortino/Calmar/CVaR, diagnostic d'overfitting, généralisation cross-actifs.
<code>walk_forward.py</code>	Validation	Réentraînements glissants (fenêtre croissante ancrée), une année de test 100 % out-of-sample par fold, grille année×actif.
<code>dashboard.py</code> <code>tests/</code>	Visualisation Qualité	Application Streamlit interactive. 74 tests pytest : pipeline de données, mécanique de trading, conformité Gymnasium, entraînements PPO courts réels, évaluation, walk-forward, dashboard.
<code>reports/</code>	Présentation	Ce rapport, les figures, <code>build_assets.py</code> (figures + dashboard statique <code>docs/index.html</code>).

Table 1 – Organisation du dépôt.




Figure 1 – Le flux du projet. Chaque étage est validé par des tests indépendants (données synthétiques, sans réseau) avant d'être branché au suivant.

3 Base théorique : du RL au trading

3.1 Le trading comme processus de décision markovien

L'apprentissage par renforcement modélise un *processus de décision markovien* (MDP) : à chaque jour de bourse t , l'agent observe un état s_t , choisit une action a_t selon sa politique $\pi(a_t | s_t)$, reçoit une récompense r_t , et l'environnement transitionne vers s_{t+1} . L'objectif est de

maximiser l'espérance de la somme actualisée des récompenses $\mathbb{E}[\sum_t \gamma^t r_t]$, avec $\gamma = 0,99$: l'agent « voit » environ $1/(1 - \gamma) = 100$ jours devant lui, un horizon cohérent avec du trading journalier.

Deux termes que j'emploierai partout : un **épisode** est une traversée de la simulation, du point de départ jusqu'à la fin des données ou au déclenchement du stop ; une **seed** est la graine du générateur pseudo-aléatoire — la fixer rend chaque expérience exactement reproductible (indispensable pour comparer deux versions du code à conditions identiques).

Le trading comme processus de décision markovien (MDP)




Figure 2 – La boucle fondamentale du RL. À chaque jour de bourse, l'agent lit un état, choisit une action, la passe à l'environnement, qui renvoie le nouvel état et une récompense. Tout le reste du rapport n'est qu'un remplissage de plus en plus soigné de ces quatre cases.

Observation. Une fenêtre glissante de 10 jours $\times$ 5 features de marché (section 4), plus deux variables de portefeuille : la position courante (-1 short, 0 cash, $+1$ long) et le PnL latent. Soit $10 \times 5 + 2 = 52$ entrées. Remarque théorique honnête : les prix de marché ne sont évidemment pas markoviens dans une fenêtre de 10 jours — l'hypothèse MDP est une approximation, partiellement compensée par des features qui résument le passé (volatilité, momentum).

Actions. {Hold, Long, Flat, Short}. Le short est essentiel : sans lui, le mieux qu'un agent puisse faire dans un marché baissier est de *ne pas perdre* (rester cash) ; avec lui, il peut *gagner* pendant les baisses — c'est exactement ce qui se produit en 2022 (figure 8).

3.2 PPO en deux idées

PPO (*Proximal Policy Optimization*) est un algorithme de *policy gradient* : un réseau de neurones (ici volontairement petit, 2×64) produit directement la distribution sur les actions, améliorée par montée de gradient sur l'avantage estimé A_t (« cette action a-t-elle rapporté plus que ce que la valeur de l'état laissait espérer ? »). Sa spécificité est le *clipping* :

$$L(\theta) = \mathbb{E}_t [\min(\rho_t(\theta) A_t, \text{clip}(\rho_t(\theta), 1 - \varepsilon, 1 + \varepsilon) A_t)], \quad \rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)},$$

qui borne l'ampleur de chaque mise à jour de politique (ici $\varepsilon = 0,15$). Sur des rendements financiers — un signal au ratio bruit/information écrasant — cette prudence n'est pas un détail d'implémentation : sans elle, une séquence chanceuse suffirait à faire basculer toute la politique.

Le clipping PPO borne l'incitation : au-delà de $1 \pm \epsilon$, le gradient s'annule (plateau)
→ aucune mise à jour ne « surexploite » un lot d'expérience




Figure 3 — Le mécanisme central de PPO. L'objectif suit le gain espéré $\rho_t A_t$ tant que la nouvelle politique reste proche de l'ancienne ($\rho_t \in [1 - \epsilon, 1 + \epsilon]$), puis *plafonne* : au-delà, augmenter encore la probabilité de l'action n'apporte plus rien au gradient. On ne peut donc jamais « tout miser » sur un lot d'expérience chanceux — exactement la garde-fou qu'exigent des données aussi bruitées que des rendements.

Trois rouages qu'il faut savoir expliquer :

- **fonction de valeur** : un second réseau estime $V(s_t)$, « ce que cet état devrait rapporter en moyenne » ; l'avantage A_t mesure ce que l'action a rapporté *au-delà* de cette attente — c'est lui qui dit au gradient quoi renforcer ;
- **bonus d'entropie** (coefficient 0,05) : un petit terme qui récompense le fait de garder des probabilités d'action diversifiées ; sans lui, la politique se fige prématurément sur une action (typiquement « toujours Hold » ou « toujours Long ») avant d'avoir exploré les alternatives ;
- **normalisation des observations** (VecNormalize) : pendant l'entraînement, moyenne et variance *glissantes* de chaque composante de l'observation sont maintenues, et les observations sont standardisées à la volée. Distinct du scaler des features (section 4) : il couvre aussi position et PnL, et ses statistiques doivent être *sauvegardées avec le modèle* — un modèle nourri d'observations brutes à l'évaluation produit du non-sens, comme je l'ai appris à mes dépens (section 5.3).

3.3 Trois choix de conception — et les alternatives écartées

- **PPO plutôt que DQN ou SAC**. Trois familles existaient : les méthodes *value-based* (DQN : apprendre $Q(s, a)$ puis agir gloutonnement — réputées instables sur des récompenses bruitées et non stationnaires, et sujettes à la surestimation des valeurs) ; les *policy gradients on-policy* (A2C, PPO : optimiser directement la politique sur l'expérience fraîche) ; les méthodes *off-policy continues* (SAC, TD3 : efficaces en données mais pour actions continues et plus délicates à régler). PPO gagne pour moi par sa **stabilité** (le clipping borne chaque mise à jour — crucial quand le signal est du bruit à 95 %), son support natif des actions discrètes, et son statut de standard reproductible dans Stable-Baselines3.
- **Actions discrètes (4) plutôt que continues**. Le tout-ou-rien simplifie l'apprentissage et rend chaque action *économiquement lisible* (long, cash, short) — au prix d'une gestion du risque binaire, limite documentée en section 12 ; le passage à une position continue $[-1, 1]$ est le levier suivant.

- **Données journalières.** Compromis entre le bruit (l'intraday exigerait de modéliser la microstructure que mon simulateur ignore) et la quantité d'expérience (le mensuel n'offrirait que ~ 150 décisions par actif). Au pas journalier, $13 \text{ ans} \times 5 \text{ actifs} \approx 16\,000$ jours de décision.

3.4 Single-agent, multi-actifs, multi-agents : ne pas confondre

Trois notions que je tiens à distinguer précisément, parce que la confusion est fréquente (et que mon propre vocabulaire de projet peut la créer) :

- **Single-agent, mono-actif** : un décideur, un actif (mon modèle « Single », entraîné sur AAPL seul). L'environnement est stationnaire du point de vue de l'agent — au sens où ses propres actions n'influencent pas les prix.
- **Single-agent, multi-actifs** : c'est mon modèle « Multi (5 tickers) » : *un seul* agent, entraîné sur les données de cinq actifs (chaque épisode se déroule sur un actif, tiré au hasard). Ce n'est PAS du multi-agents : c'est de la *régularisation par diversité des données* — pour être bon sur AAPL, MSFT, GOOGL, SPY et TSLA à la fois, il faut des règles générales, pas une trajectoire apprise par cœur.
- **Multi-agents (MARL)** : plusieurs politiques *apprennent simultanément* et interagissent. La difficulté fondamentale : du point de vue de chaque agent, l'environnement devient *non stationnaire*, puisque les autres agents changent en apprenant — les garanties de convergence du RL classique sautent. La réponse standard est le CTDE (*centralized training, decentralized execution*) : un critique centralisé qui voit tout pendant l'entraînement, des politiques décentralisées à l'exécution (MAPPO, MADDPG). C'est la phase suivante de ma roadmap : ajouter un *adversaire de marché* qui apprend à créer les scénarios les plus défavorables (chocs de liquidité, pics de volatilité) — de l'*adversarial training* pour forcer la robustesse, précisément la faiblesse que le walk-forward va révéler (section 7).

4 Features : le pont avec l'économétrie

Chaque feature que je donne à l'agent répond à un problème identifié en économétrie des séries temporelles.

Feature	Définition	Notion d'économétrie associée
log_returns	$r_t = \ln(P_t/P_{t-1})$	Les prix sont $I(1)$ (non stationnaires, cf. test ADF) : je travaille sur la série différenciée, stationnaire en moyenne, comme pour toute modélisation ARMA.
volatility	écart-type glissant de r_t sur 20 jours	Estimateur naïf de σ_t : proxy du <i>volatility clustering</i> modélisé par GARCH(1,1), $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ (Engle, Bollerslev). L'agent observe le régime de volatilité sans estimer le modèle.
rsi	oscillateur borné $[0, 1]$ sur 14 jours	Signal de sur-achat/sur-vente : pari de <i>retour à la moyenne</i> local — l'esprit d'un processus d'Ornstein-Uhlenbeck, $dX_t = \kappa(\mu - X_t)dt + \sigma dW_t$, qui rappelle la variable vers sa moyenne μ à vitesse κ , sans son estimation paramétrique.
macd_norm	$(\text{EMA}_{12} - \text{EMA}_{26})/\text{EMA}_{26}$	Détection de tendance par différence de moyennes mobiles exponentielles — un filtre linéaire de la série des prix.
momentum_5	rendement sur 5 jours	Anomalie <i>momentum</i> (Jegadeesh & Titman, 1993) : autocorrélation positive des rendements à moyen terme, une des violations les plus documentées de l'efficience faible.

Table 2 – Correspondance features $\leftrightarrow$ économétrie.

Le biais de look-ahead, version machine learning. En économétrie, on n'évalue jamais un modèle sur l'échantillon qui a servi à l'estimer. Ici, l'équivalent se niche dans un détail : la *normalisation*. Le **RobustScaler** (centrage médiane, réduction par écart interquartile — robuste aux queues épaisses des rendements) est **fitté sur le train uniquement**, puis appliqué tel quel à la validation et au test. Le fitter sur tout l'échantillon reviendrait à injecter dans les observations de 2015 des statistiques calculées avec les données de 2022 : de l'information future. Un test unitaire verrouille ce point en comparant les paramètres du scaler à ceux d'un scaler fitté manuellement sur le train seul.




Figure 4 — Split temporel strict 70/15/15 sur AAPL 2010→2023. Le train couvre plusieurs cycles (2011, 2015, 2018), la validation contient le krach COVID et sa reprise, le test enchaîne bull 2021 et bear 2022. C’est l’équivalent de l’évaluation out-of-sample d’un modèle économétrique.

Zoom : le retour à la moyenne et le processus d’Ornstein-Uhlenbeck. C’est le modèle canonique du retour à la moyenne en temps continu :

$$dX_t = \kappa(\mu - X_t) dt + \sigma dW_t,$$

où μ est le niveau de long terme, $\kappa > 0$ la *vitesse de rappel* (plus κ est grand, plus vite tout écart se résorbe) et σdW_t le choc brownien. Deux quantités à savoir manier : la **demi-vie** d’un écart, $t_{1/2} = \ln 2 / \kappa$ (« en combien de jours la moitié de l’écart à μ est-elle effacée ? »), et le lien direct avec l’économétrie : *discrétisé, un OU est exactement un AR(1)*, $X_{t+1} = \mu(1 - \varphi) + \varphi X_t + \varepsilon_t$ avec $\varphi = e^{-\kappa \Delta t}$ — on estime donc κ par une simple régression MCO de X_{t+1} sur X_t (dérivation complète en annexe A.4). Dans ce projet, je n’estime pas d’OU : le RSI en est le cousin non paramétrique (un oscillateur borné qui signale les écarts extrêmes susceptibles de se résorber). Mais le cadre OU est celui que j’utiliserais pour trader un *spread* de paires cointégrées — le projet suivant sur ma liste — et c’est le vocabulaire attendu en entretien dès qu’on dit « mean reversion ».




Figure 5 — Trois processus d’Ornstein-Uhlenbeck partant du même écart initial. Plus la vitesse de rappel κ est grande, plus vite la trajectoire revient vers μ — la *demi-vie* $\ln 2 / \kappa$ quantifie ce « temps de retour ». C’est l’objet qu’un stratège stat-arb estime sur le spread d’une paire avant de décider s’il vaut la peine d’être tradé.

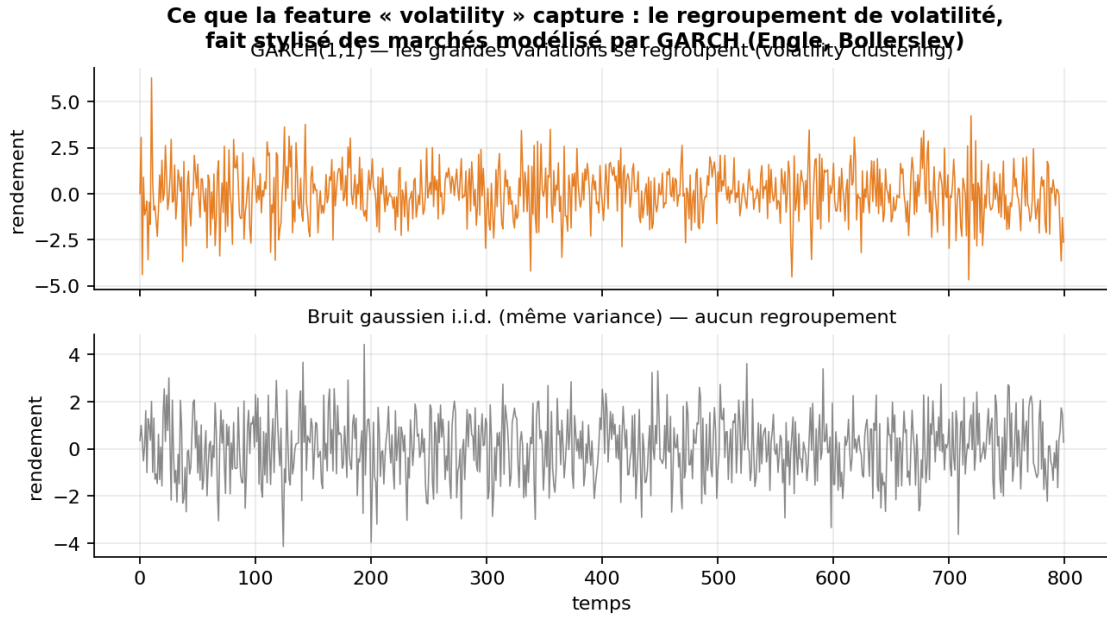


Figure 6 — Ce que la feature *volatility* donne à voir à l’agent. En haut, un GARCH(1,1) : les grandes variations s’agglutinent (une journée agitée en annonce une autre) — le *volatility clustering*, fait stylisé omniprésent des marchés. En bas, un bruit gaussien de même variance : aucune structure. La rolling-std de 20 jours est un estimateur naïf de l’état de volatilité du haut.

4.1 Pourquoi ma récompense est un alpha de Jensen par pas de temps

Mon premier réflexe avait été une récompense de type Sharpe par pas. Symptôme observé : l’agent devenait « toujours long ». Diagnostic : comme le marché monte en moyenne sur la période, *suivre le marché* suffit à collecter du rendement — la récompense ne distinguait pas « profiter du marché » de « battre le marché ». J’ai donc changé la cible : à chaque pas,

$$r_t = \underbrace{\left(\frac{V_t - V_{t-1}}{V_{t-1}} - \frac{P_t - P_{t-1}}{P_{t-1}} \right)}_{\text{alpha du pas } t} \times 100 - \text{pénalité de frais} - 0,05 \times \text{drawdown},$$

où V_t est la valeur du portefeuille et P_t le prix. Le premier terme est un **alpha de Jensen** dans le cas particulier $\beta = 1$, $R_f = 0$:

$$\alpha_J = R_p - [R_f + \beta (R_m - R_f)] \xrightarrow{\beta=1, R_f=0} R_p - R_m.$$

Être long quand ça monte ne rapporte plus rien (alpha ≈ 0) ; être cash ou short quand ça baisse rapporte ; rater une hausse coûte. L’agent est payé pour *timer*, pas pour *suivre*. Le facteur $\times 100$ est une mise à l’échelle : PPO apprend bien avec des récompenses d’ordre de grandeur ~ 1 , alors qu’un return journalier brut ($\sim 0,01$) donnerait un signal de gradient trop faible.

Les deux pénalités sont des outils de gestion classiques : les **frais** (0,1 % par transaction, débités du portefeuille *et* pénalisés dans la récompense) découragent l’overtrading ; la pénalité de **drawdown** introduit une aversion au risque asymétrique, complétée par un *kill-switch* : tout épisode dont le drawdown dépasse 25 % s’arrête — l’équivalent d’un stop-loss de mandat.

4.2 Métriques d’évaluation

Toutes viennent du cours de gestion de portefeuille :

- **Sharpe** = $\frac{\bar{r}}{\sigma} \sqrt{252}$: rendement par unité de risque total (critère moyenne-variance de Markowitz) ;

- **Sortino** : idem avec l'écart-type des seuls rendements négatifs (semi-variance) — on ne pénalise pas la volatilité haussière ;
- **Max drawdown** : perte maximale depuis un pic, le risque « vécu » ;
- **Calmar** = rendement annualisé / max drawdown ;
- **CVaR₉₅** (Expected Shortfall) = $\mathbb{E}[r \mid r \leq \text{VaR}_{95}]$, où la VaR_{95} est simplement le quantile à 5 % des rendements journaliers (« le seuil de perte dépassé un jour sur vingt »). La CVaR répond à la question suivante : *quand* ce seuil est franchi, combien perd-on en moyenne ? Contrairement à la VaR, c'est une mesure cohérente (sous-additive), celle de la réglementation bancaire récente.

5 Chronologie : ce qui ne marchait pas, ce que j'ai changé

C'est le cœur du rapport. Chaque itération suit le même schéma : *symptôme observé* → *diagnostic* → *pourquoi c'est grave financièrement* → *décision* → *résultat mesuré* → *ce que ça ouvre*.

5.1 Point de départ

Deux modèles PPO entraînés sur 2018–2023 (un mono-actif AAPL, un multi-actifs), récompense alpha, observations normalisées par **VecNormalize**. Mon évaluation d'alors donnait : Single battant le B&H sur 3 tirages sur 5 (alpha moyen $+8,5\% \pm 10,2$), Multi négatif ($-4,7\%$, 0/5).

Trois symptômes me gênaient : (i) une variance énorme entre tirages (± 10 à 15 points — comment conclure quoi que ce soit ?), (ii) un alpha d'entraînement de plusieurs milliers de pourcents (personne ne croit ça : mémorisation), (iii) un Multi « toujours long », alors que sa raison d'être était justement de généraliser. *Avant de toucher au modèle, j'ai décidé de fiabiliser tout ce qui produit les chiffres.*

5.2 Itération 1 — des tests, parce qu'un simulateur faux rend tout faux

En finance simulée, un test ne vérifie pas que « le code tourne » : il vérifie que *l'économie du simulateur est juste*. J'ai écrit une suite de tests qui fixe des vérités comptables : un aller-retour long à prix constant doit coûter exactement $(1 - c)^2$ du capital ; un short doit gagner quand le prix baisse ; le kill-switch doit se déclencher au bon seuil ; la normalisation ne doit rien voir du futur.

Résultat : les tests ont immédiatement trouvé une asymétrie — **les frais d'ouverture d'un short n'étaient pas débités du portefeuille** (ils réduisaient seulement la taille de position), contrairement au long. Un simulateur qui sous-facture le short gonfle mécaniquement toute stratégie qui shorte : exactement le genre de biais qui fabrique de faux alphas. Corrigé, verrouillé par un test de symétrie.

Ce que ça ouvre : avec un simulateur fiable, je peux maintenant regarder si mes chiffres d'évaluation, eux, sont crédibles.

5.3 Itération 2 — mon protocole d'évaluation mentait

Trois défauts faussaient les *conclusions*, indépendamment de la qualité des modèles :

1. **Observations non normalisées à l'évaluation**. Le modèle est entraîné sur des observations standardisées ; deux scripts prédisaient sur observations *brutes*. C'est comme estimer une régression sur variables centrées-réduites puis prédire sur variables en niveau : les sorties n'ont aucun sens.
2. **Frais d'évaluation $\neq$ frais d'entraînement** (0,2 % vs 0,1 %) : j'évaluais l'agent dans un monde deux fois plus coûteux que celui où il avait appris à trader.

3. **Évaluation sur fenêtres aléatoires uniquement**, d'où la variance de ± 15 points. Pire : un épisode arrêté par le kill-switch se termine *par construction* à son point bas, et était comparé à un B&H calculé sur une fenêtre différente — des alphas incomparables entre modèles.

Décision : un protocole de référence **déterministe sur le split complet** (départ fixe, politique déterministe, reproductible au centime) ; si le kill-switch se déclenche, la stratégie est réputée liquidée et **reste en cash jusqu'à la fin de la fenêtre** — tous les modèles et le B&H sont ainsi comparés sur le même horizon. Les fenêtres aléatoires deviennent une mesure *complémentaire* de robustesse au point d'entrée.

Ce que ça ouvre : des chiffres enfin stables — et donc la possibilité de voir qu'il restait un vrai problème de données.

5.4 Itération 3 — plus de cycles de marché

Symptôme : mon test d'origine (avril-décembre 2022) était un bear pur. Interprétation financière : sur une telle période, un agent simplement *peureux* paraît génial — biais de période classique du backtesting. **Décision** : réentraîner sur 2010→2023 ($2,6\times$ plus de données, plusieurs corrections dans le train, validation contenant le COVID) avec un test 2021–2022 qui enchaîne hausse et baisse.

Ce que ça ouvre : un cadre assez propre pour que le dernier symptôme — le Multi toujours décevant — ne puisse plus s'expliquer que par une vraie cause.

5.5 Itération 4 — le bug décisif : ma validation était corrompue

Symptôme : après réentraînement, le Multi restait mauvais (alpha test négatif, biais long), et les logs d'entraînement montraient des drawdowns de validation de 45 à 50 % — physiquement impossibles avec un kill-switch à 25 %.

Diagnostic : le pipeline multi-actifs concatène les données des cinq tickers. Un identifiant de segment garantissait que les épisodes d'*entraînement* ne franchissent pas la frontière entre deux actifs... mais pas ceux de la *validation*. Un épisode de validation pouvait donc passer du dernier jour de GOOGL ($\sim 1\,000$ \$) au premier jour de SPY (~ 300 \$) : un krach fictif de -70% en un jour.

Pourquoi c'est grave : c'est précisément sur cette validation que l'`EvalCallback` choisit le *best model* conservé à la fin. **Je sélectionnais mon meilleur modèle sur du bruit** — l'équivalent économétrique d'un critère de choix de modèle calculé sur un échantillon pollué.

Décision et résultat : une ligne de correction (segments sur les trois splits), un réentraînement — le Multi passe à **+27,5 % d'alpha** sur le test, avec un alpha positif sur **5/5 actifs** (figure 10) et une répartition d'actions enfin équilibrée. La leçon que je retiens : *la sélection de modèle vaut ce que vaut le signal de validation.*

La preuve propre : une ablation contrôlée. Le tableau 4 a une faiblesse méthodologique que je préfère lever moi-même : entre « départ » et « final », j'ai changé plusieurs choses (dates, protocole, frais du short, bug de validation) — c'est un *confondage*, on ne sait pas quelle cause a produit quel effet. J'ai donc mené l'expérience contrôlée : réentraîner le Multi **en ne réintroduisant que le bug** (validation sans segments), tout le reste strictement identique (données 2010–2023, seed, 800 000 pas, protocole d'évaluation final).

Multi, toutes choses égales par ailleurs	Validation corrompue	Validation propre
Alpha test AAPL	−2,4 %	+27,5 %
Actifs à alpha positif	3/5	5/5
Alpha cross-actifs moyen	+10,4 %	+17,2 %

Table 3 – Ablation contrôlée du bug de validation : effet causal isolé $\approx +30$ points d’alpha sur AAPL. Détail du modèle corrompu : TSLA +37 %, GOOGL +20,5 %, MSFT +5,9 %, AAPL −2,4 %, SPY −8,8 %.

Le détail est aussi instructif que la moyenne : le modèle sélectionné sur une validation bruitée n’est pas *uniformément* mauvais — il est *erratique* (excellent sur TSLA, négatif sur AAPL et SPY). C’est exactement ce que prédit la théorie : sélectionner sur du bruit revient à tirer un checkpoint *au hasard* parmi les versions du réseau — une loterie, dont on gagne certains tickets. La validation propre ne rend pas le modèle plus intelligent ; elle rend sa sélection *systématique* au lieu d’aléatoire.

Ce que ça ouvre : des résultats crédibles sur UN split. Reste la question qu’un professionnel poserait immédiatement : et sur les autres périodes ? (section 7).

5.6 Récapitulatif chiffré

Indicateur (test set)	Départ (2018-23, protocole v0)	Après itérations 1–4 (2010-23, protocole final)	
Alpha Single	+8,5 % $\pm$ 10,2	+19,2 %	↑
Alpha Multi	−4,7 % $\pm$ 2,8	+27,5 %	↑
Fenêtres où Single > B&H	3/5	5/5	↑
Fenêtres où Multi > B&H	0/5	5/5	↑
Actifs à alpha positif (Multi)	1/5	5/5	↑
Répartition des actions (Multi)	biais long	équilibrée (short 23 %)	↑

Table 4 – Avant/après. Les protocoles diffèrent entre colonnes *parce que corriger le protocole fait partie des améliorations* ; chaque chiffre est mesuré avec le protocole en vigueur à son étape (section 5.3). L’effet du bug de validation *seul*, toutes choses égales par ailleurs, est isolé par l’ablation contrôlée du tableau 3.




Figure 7 – Synthèse graphique du tableau 4.

6 Résultats sur le split de référence

6.1 Test AAPL, février 2021 → décembre 2022

Modèle	Return	Alpha	MaxDD	Sharpe	Sortino	Calmar	CVaR ₉₅
Single (AAPL)	+15,5 %	+19,2 %	26,2 %	0,44	0,57	0,30	−3,4 %
Multi (5 actifs)	+23,8 %	+27,5 %	25,2 %	0,57	0,77	0,47	−3,7 %
Buy & Hold (réf.)	−3,7 %	—	30,3 %	—	—	—	—

Table 5 — Évaluation déterministe sur le split complet. Robustesse : les deux modèles battent le B&H sur 5/5 sous-fenêtres aléatoires (Single +9,0 % $\pm$ 4,9, Multi +8,1 % $\pm$ 3,1).

Mise à jour (Acte 3, section 9.1). L’alpha *mono-actif* de ce tableau porte une incertitude de ± 21 points selon le seed d’entraînement — le +27,5 % vient du haut de la distribution. La statistique robuste est la moyenne cross-actifs : +14,5 % $\pm$ 6,5, **positive pour 5 seeds sur 5** sur cette fenêtre de test.




Figure 8 — Valeur du portefeuille sur le test. Lecture : les agents suivent la hausse de 2021 (le Multi la surperforme), encaissent une partie du retournement de 2022, puis le kill-switch les sort du marché (▼) — ils finissent en cash pendant que le B&H replonge. Une part importante de l’alpha vient de cette *non-exposition* finale : vraie décision de gestion du risque, mais il faut le dire — et la section 7 montrera ce que ça implique.




Figure 9 – Drawdown depuis le pic : les agents restent bornés par le kill-switch à -25% quand le B&H dépasse -30% .

6.2 Généralisation cross-actifs




Figure 10 – Alpha du Multi sur le test de chaque actif : positif sur 5/5, moyenne $+17,2\%$. Un modèle qui aurait mémorisé AAPL ne transférerait pas sur TSLA ($+28,6\%$) ni GOOGL ($+12,7\%$).




Figure 11 – Répartition des actions sur le test complet. Le Multi est équilibré (short 23 % du temps) là où sa version pré-correction était longue en quasi-permanence.

À ce stade, j'avais un résultat solide *sur une période*. Mais je savais — pour l'avoir écrit moi-même dans les limites — qu'un backtest unique est *un tirage*, pas une distribution. La suite s'imposait d'elle-même.

7 Du backtest unique au walk-forward

7.1 Pourquoi c'était la priorité (et pas la diffusion ou le MARL)

Mes lectures me tiraient vers l'avant : politiques par diffusion, génération de scénarios synthétiques, multi-agents. Mais je me suis imposé trois questions avant de choisir :

1. *Ma conclusion actuelle est-elle fiable ?* Non — elle repose sur une seule période de test, choisie par moi.
2. *Qu'est-ce qu'un professionnel me demanderait en premier ?* « Montre-moi la stabilité temporelle » — pas « ajoute un modèle de diffusion ».
3. *Que vaut une sophistication bâtie sur une évaluation fragile ?* Rien : je ne saurais même pas dire si elle améliore quoi que ce soit.

Décision : consolider la fondation d'abord. Le *walk-forward* est le standard du backtesting sérieux : on réentraîne le modèle en ne voyant que le passé, on le teste sur l'année suivante, on avance, on répète. C'est la généralisation dynamique du principe out-of-sample de l'économétrie : non pas *un* échantillon de test, mais une *séquence* d'échantillons de test, chacun prédit par un modèle qui ne connaît que son passé.

7.2 Protocole

Fenêtre *croissante ancrée* (anchored) : pour chaque année de test $Y \in \{2018, \dots, 2022\}$, j'entraîne sur $[2010, Y)$ (dont les derniers 15 % servent de validation pour la sélection du best model), puis j'évalue sur l'année Y — 100 % out-of-sample — pour chacun des cinq actifs. Soit 5 réentraînements complets et $5 \times 5 = 25$ cellules année×actif. Deux limites assumées : 400 000 pas d'entraînement par fold (contre 800 000 pour le modèle de référence, pour un temps de calcul raisonnable), et des folds anciens qui voient moins d'histoire.




Figure 12 — Le protocole en image. Chaque ligne est un fold : le modèle n'apprend que sur le passé (vert, ancré à 2010) et n'est jugé que sur l'année suivante (orange), jamais vue. En avançant fold après fold, on obtient une *séquence* de tests out-of-sample au lieu d'un seul — la généralisation dynamique du principe de l'échantillon de test en économétrie.

7.3 Ce que j'avais prédit — et ce qui s'est passé

Avant de lancer, j'ai noté ma prédiction : *l'alpha moyen serait nettement plus faible que le +27,5 % du split unique — 2022 étant l'année rêvée pour un agent défensif — mais je m'attendais à une médiane positive*. La première moitié s'est vérifiée. La seconde non : médiane $-2,0\%$, 48 % de cellules positives. Et c'est la moitié fausse qui m'a le plus appris.

Année OOS	Agent (moy.)	B&H (moy.)	Alpha	Régime
2018	+5,2 %	-4,0 %	+9,2 %	année baissière
2019	+21,2 %	+42,2 %	-21,0 %	bull soutenu
2020	-3,0 %	+143,3 %	-146,4 %	krach puis rebond violent
2021	+32,2 %	+43,3 %	-11,1 %	bull
2022	+6,2 %	-31,4 %	+37,6 %	bear
Agrégat : alpha moyen $-26,3\%$ (médiane $-2,0\%$, écart-type 106 %), 48 % de cellules > 0 .				

Table 6 — Walk-forward, moyennes par fold sur les 5 actifs. La moyenne est écrasée par 2020 — en particulier la cellule TSLA (B&H +576 %, alpha -514 %) : rater UNE année de rebond extrême coûte plus que tout ce que la défense rapporte ailleurs.




Figure 13 — À gauche : return absolu de l'agent (orange) vs B&H (bleu) par année out-of-sample. À droite : grille des 25 alphas (couleur tronquée à $\pm 100\%$). Le motif est net : vert sur les lignes 2018 et 2022 (marchés baissiers), rouge sur 2019–2021 (marchés haussiers).

7.4 Interprétation financière : un profil, pas un alpha universel

- **L'agent est un profil défensif régime-dépendant.** Alpha nettement positif les années baissières (2018 : $+9\%$; 2022 : $+38\%$), proche de zéro à négatif en marché haussier, catastrophique — *relativement au B&H* — dans un rebond violent (2020 : stoppé dans le krach, il reste défensif pendant que le marché fait $+143\%$).
- **En absolu, le tableau est différent** : rendement positif 4 années sur 5, et $+5$ à $+6\%$ les deux années où le B&H perd. Comme brique *absolute return* défensive dans une allocation, le profil est cohérent ; comme stratégie « qui bat le marché », non.
- **Mon $+27,5\%$ du split unique n'était donc pas faux, mais partiel** : 2021–2022 contient précisément le régime où ce profil excelle. C'est la démonstration empirique, sur mon propre projet, du biais de période — je l'avais énoncé en théorie à l'itération 3, le walk-forward le quantifie.
- **Moyenne vs médiane** : l'écart (-26% vs -2%) vient d'une queue gauche épaisse (TSLA 2020). Réflexe d'économètre : sur des distributions asymétriques à outliers, la médiane est la

statistique robuste — mais ici l’outlier n’est pas une erreur de mesure, c’est un vrai scénario de marché : le coût d’opportunité des rebonds fait partie du risque de la stratégie.

7.5 Ce que ça ouvre

Le diagnostic « défensif partout, y compris quand il ne faudrait pas » pointe vers une cause précise : l’agent n’observe rien qui lui permette de *distinguer les régimes* — il applique la même prudence dans un krach durable et dans un rebond en V. Trois pistes, par ordre de priorité que je me fixe :

1. **features de régime** (tendance longue, distance au plus-haut d’un an, vitesse de reprise) — l’esprit des modèles à changement de régime de type *Markov-switching* (Hamilton, 1989), vus en économétrie : les paramètres du processus sautent entre quelques états latents (bull, bear) pilotés par une chaîne de Markov cachée, et on infère l’état courant à partir des données. *Piste testée depuis, et falsifiée — voir la section 9.2*;
2. **position continue** (action $\in [-1, 1]$) au lieu du tout-ou-rien, pour que la défense soit graduelle et non binaire ;
3. **adversarial training multi-agents** (section 3.4) et génération de scénarios par diffusion — ma roadmap initiale — qui ne prennent leur sens que maintenant : j’ai enfin un protocole capable de mesurer si elles améliorent la robustesse.

8 Stress-tests : les questions qu’un desk poserait

Pour juger mon propre travail, je me suis mis dans la peau d’un trader qui lit ce rapport. Ses deux premières questions sont prévisibles — alors autant y répondre avec des mesures plutôt que des arguments. Aucun réentraînement ici : je stresse les *hypothèses d’exécution et de risque*, à politique fixée (`evaluate.stress_report()`).

8.1 « Ton alpha survit-il à des frais réalistes ? »

Mes modèles sont entraînés avec 0,10 % de frais par trade. J’évalue les mêmes politiques sous une grille de coûts — une façon de proxyser spread, slippage et (partiellement) le coût d’emprunt des shorts que mon simulateur ne modélise pas :

Alpha (test)	0 bp	5 bp	10 bp	20 bp	30 bp
Single (AAPL), 259 trades	+24,9 %	+22,0 %	+19,2 %	+13,8 %	+8,7 %
Multi (5 actifs), 301 trades	+28,7 %	+28,0 %	+27,5 %	+25,7 %	+ 23,7 %

Table 7 – Sensibilité de l’alpha au niveau de frais par trade (test AAPL 2021–2022). 1 bp (point de base) = 0,01 % ; 10 bp = niveau d’entraînement.

Réponse : **l’edge du Multi n’est pas un artefact de coûts** — il ne perd que 5 points d’alpha entre 0 et 30 bp, soit trois fois le niveau de frais auquel il a été entraîné. Le Single, lui, se dégrade nettement (−16 points sur la grille) : son avantage est plus fragile à l’exécution.

8.2 « Que reste-t-il si j’enlève ton kill-switch ? »

La figure 8 suggérerait qu’une part importante de l’alpha 2022 venait de la sortie du marché sur stop. Je l’ai quantifiée : mêmes politiques, drawdown libre (seul le stop de quasi-ruine à 5 % du capital subsiste).

Sans kill-switch	Return	Alpha	MaxDD	Contribution du stop
Single (AAPL)	-5,4 %	-1,7 %	44,9 %	+21,0 points
Multi (5 actifs)	+1,4 %	+5,1 %	40,4 %	+22,3 points

Table 8 — Ablation du kill-switch sur le test. « Contribution du stop » = alpha avec stop – alpha sans stop (la règle inclut la non-réexposition jusqu’à la fin de la fenêtre).

La réponse est la découverte la plus importante de ce projet après le walk-forward : **environ 21 points d’alpha sur 2022 viennent de la règle de stop, pas du timing quotidien**. Sans elle, le Single ne bat plus le marché du tout (-1,7 %) ; le Multi conserve un alpha de décision modeste mais réel (+5,1 %), en subissant un drawdown de 40 %.

Interprétation en langage de desk : je distingue désormais *l’alpha de signal* (les décisions jour par jour — faible mais positif pour le Multi) de *l’alpha de règle de risque* (couper l’exposition sur drawdown — majoritaire ici). Ce n’est pas disqualifiant : le stop fait partie de la stratégie que j’ai conçue, et c’est lui qui borne le MaxDD à 25 % quand le marché fait -30 %. Mais vendre ce système comme du « market timing par RL » serait faux : c’est *une discipline de risque systématique, aidée par un signal RL modeste*. Cette phrase résume honnêtement le projet.

8.3 Les questions restantes — et celle qui a depuis reçu sa mesure

- *Sensibilité au seed d’entraînement* : mesurée depuis à l’Acte 3 (section 9.1) — ± 21 points sur un actif isolé, $\pm 6,5$ sur la moyenne cross-actifs, positive pour 5 seeds sur 5.
- *Coût d’emprunt des shorts* : non modélisé explicitement (le stress de frais le capture partiellement) ; sur des titres chers à emprunter, l’alpha short de 2022 serait rogné.
- *Exécution au cours de clôture* : pas d’écart d’exécution intrajournalier ni d’impact de marché.

9 Acte 3 : attaquer la dépendance de régime

Le diagnostic est posé (sections 7 et 8) : profil défensif régime-dépendant, alpha majoritairement porté par la règle de stop. La suite logique saute aux yeux — « rendre l’agent conscient des régimes ». Mais avant de tester le moindre traitement, il me manque une chose : **une barre d’erreur**. Le RL profond est notoirement sensible au hasard d’initialisation (poids du réseau, ordre d’exploration) ; tant que je ne connais pas la dispersion de mes résultats d’un seed à l’autre, je ne peux pas distinguer une amélioration réelle d’un tirage chanceux. D’où le plan de cet acte : (1) mesurer le bruit, (2) tester le traitement, (3) conclure *hors bruit*.

9.1 D’abord la barre d’erreur : cinq seeds

Protocole. Quatre réentraînements complets du Multi, strictement identiques au modèle de référence (données 2010–2023, 800 000 pas, validation propre), en ne changeant que le seed — 7, 123, 777, 2024, plus le 42 existant. Un détail qui aurait tout invalidé : le seed était *codé en dur* dans l’appel à PPO ; sans le paramétrer d’abord, mes « cinq entraînements » auraient été cinq copies du même tirage.

Ce que j’avais prédit. Une dispersion non triviale mais un signe stable — alpha AAPL positif pour au moins 4 seeds sur 5.

Seed	Alpha AAPL	Alpha cross-actifs (moy.)	Actifs > 0
7	+43,6 %	+16,5 %	4/5
42 (référence)	+27,5 %	+17,2 %	5/5
123	-5,1 %	+10,6 %	3/5
777	-2,3 %	+23,7 %	3/5
2024	-11,2 %	+4,3 %	3/5
Moyenne $\pm$ écart-type	+10,5 % $\pm$ 21,3	+14,5 % $\pm$ 6,5	—

Table 9 — Robustesse au seed d’entraînement (test 2021–2022, protocole identique au tableau 5). L’alpha cross-actifs est positif pour 5 seeds sur 5.

Résultat : prédiction fausse, leçon meilleure. L’alpha *sur AAPL seul* est une loterie : de -11 à $+44$ % selon le seed, positif 2 fois sur 5 — mon $+27,5$ % de référence vient du haut de cette distribution. Mais la moyenne *sur les cinq actifs* est remarquablement plus stable et **positive pour tous les seeds**.




Figure 14 — La leçon de l’acte, en une image. Chaque colonne est un seed d’entraînement. Les points rouges (alpha d’un seul actif) sont dispersés sur ± 21 points ; les carrés verts (moyenne sur cinq actifs) tiennent dans une bande de $\pm 6,5$. Le bruit d’initialisation, largement idiosyncratique par actif, se *diversifie* en moyennant — la même mécanique que le risque spécifique dans un portefeuille.

Pourquoi cet écart ? La théorie du portefeuille, encore. Le bruit de seed frappe chaque couple (seed, actif) de manière largement idiosyncratique ; en moyennant sur cinq actifs, il se diversifie — exactement comme le risque spécifique d’un titre dans un portefeuille de Markowitz. Deux conséquences que j’applique immédiatement :

- le **chiffre défendable n’est pas l’alpha d’un actif, c’est la moyenne cross-actifs** : $+14,5\% \pm 6,5$ sur cette fenêtre de test — les sections vivantes du rapport sont mises à jour en conséquence ;
- **toute expérience future se juge contre la bande $\pm 6,5$ points** : en dessous, c’est du bruit, quel que soit l’enthousiasme.

9.2 Le traitement : des features de régime — et son échec instructif

Hypothèse et protocole. Le diagnostic du walk-forward disait : l’agent ne distingue pas un krach durable d’un rebond en V. Le traitement le plus direct consiste à *lui montrer le régime*. J’ai ajouté deux features long-terme à l’observation ($52 \rightarrow 72$ entrées) : **dist_high_252**, la position par rapport au plus-haut d’un an (le drawdown de l’actif lui-même — proche de zéro en bull, -30 % en krach), et **trend_200**, la position par rapport à la moyenne mobile 200 jours (LE proxy

de régime des praticiens). Tout le reste est identique — données 2010–2023, configuration, seed 42 — et le candidat s’entraîne dans un dossier séparé : promotion uniquement s’il bat la bande de bruit de la section 9.1.

Ce que j’avais prédit. Amélioration du fold 2020 (le pire : -146%) sans dégradation de 2022.

Alpha moyen (5 actifs)	Baseline (obs 52)	+ régime (obs 72)
2018 (bear)	+9,2 %	+30,3 % ¹
2019 (bull)	−21,0 %	−5,7 %
2020 (krach + rebond)	−146,4 %	−162,5 %
2021 (bull)	−11,1 %	−51,7 %
2022 (bear)	+37,6 %	+17,2 %
Walk-forward : médiane / cellules > 0	−2,0 % / 48 %	−2,9 % / 36 %
Test 2021-22 : cross-actifs / positifs	+17,2 % / 5 sur 5	+11,6 % / 2 sur 5

Table 10 – Baseline contre candidat « régime », même seed, même protocole.

Résultat : faux sur les deux volets.

Verdict : pas de promotion. Sur la fenêtre de test, le candidat tombe dans la bande de bruit, du mauvais côté (+11,6 %, 2 actifs positifs sur 5). Sur le walk-forward, la dégradation est cohérente précisément là où le traitement devait agir : 2020 *empire*, 2021 s’effondre, et même 2022 — la force du profil — recule. Une seule seed, certes ; mais quand toutes les années clés bougent dans le même sens, l’explication « bruit » ne tient plus.

Pourquoi cet échec est un bon résultat. Mon hypothèse d’« underfitting de représentation » est falsifiée dans sa version naïve : **voir le régime ne suffit pas à l’exploiter**. La récompense de l’agent (alpha par pas, pénalité de drawdown, kill-switch) ne valorise pas différemment la prudence selon le régime — ajouter des colonnes à l’observation ne change pas les *incitations*, et l’espace d’entrée élargi offre surtout plus de latitude pour sur-apprendre. La contrainte active n’était pas l’information mais la structure de la récompense et l’action tout-ou-rien. En économiste, je devrais reconnaître le schéma : les agents répondent aux incitations, pas aux informations qu’on leur affiche.

9.3 Bilan de l’acte

Trois acquis, dont deux méthodologiques :

1. **la revendication robuste du projet** : alpha cross-actifs $+14,5\% \pm 6,5$ sur le test 2021-22, positif pour 5 seeds sur 5 (l’alpha mono-actif, lui, est une loterie à ± 21 points) ;
2. **une barre d’erreur permanente** : toute expérience future se juge contre la bande inter-seeds, pas contre un chiffre unique ;
3. **une direction falsifiée et une nouvelle priorité** : le prochain levier n’est pas l’observation mais la récompense et le dimensionnement de position (action continue, aversion au risque dépendante du régime).

1. Tiré par une seule cellule (TSLA 2018 : $+145,6\%$) — davantage un ticket de loterie qu’un signe de clairvoyance, cf. la dispersion mesurée en section 9.1.

10 Overfitting, underfitting, régimes : le diagnostic complet

L’overfitting se voit sur le train. Le Single réalise sur son propre train un alpha de l’ordre de +16 500 % : de la **mémorisation** de trajectoire, l’équivalent d’un R^2 in-sample de 0,999. Ce chiffre ne mesure rien d’autre que la capacité du réseau à apprendre par cœur — ce qui compte est out-of-sample.

Mes remèdes. Entraînement multi-actifs (régularisation par les données) ; *early stopping* — on conserve la version du réseau qui maximise la performance de *validation*, pas la dernière : si la fin de l’entraînement sur-apprend, on ne la paie pas (d’où le caractère critique du bug de la section 5.5) ; réseau volontairement petit ; clipping PPO ; bonus d’entropie ; plus d’années de données.

Et l’underfitting ? C’est le défaut symétrique : un modèle trop simple pour capter le signal disponible, reconnaissable à de mauvaises performances *partout, y compris sur le train*. Mon alpha d’entraînement délirant prouve que la capacité ne manque pas. En revanche, le walk-forward révèle un underfitting plus subtil : un underfitting de *représentation*. Mes cinq features ne contiennent tout simplement pas l’information « dans quel régime de marché sommes-nous ? » — aucun réseau, aussi gros soit-il, ne peut apprendre à distinguer un krach durable d’un rebond en V s’il ne voit que dix jours de features court-terme. Le problème n’est pas la capacité du modèle, c’est ce que je lui donne à regarder.

La distinction que le walk-forward m’a forcé à faire. Avant, je risquais de tout appeler « overfitting ». Maintenant je sépare trois choses :

- **mémorisation** (train $\gg$ test) : présente, contenue par les remèdes ci-dessus, et visible ;
- **biais de période** (un test favorable au style du modèle) : c’était mon cas, quantifié par le walk-forward ;
- **dépendance de régime** (une stratégie dont la performance est conditionnelle à l’état du marché) : ce n’est pas un défaut d’apprentissage, c’est une caractéristique du produit — à documenter, couvrir ou conditionner, comme pour n’importe quelle stratégie systématique.

11 Acte 4 : le générateur de scénarios — mon volet IA générative

Le walk-forward avait laissé une question ouverte et chiffrée : le fold 2020 coûte un alpha moyen de -146 % (tableau 6), parce que l’agent n’a *jamais vu* de rebond en V à l’entraînement — les régimes rares sont, par définition, rares dans 13 ans d’historique. Avant tout multi-agents, j’ai donc construit ce qui manquait : un **générateur de scénarios** — un modèle de diffusion (DDPM) entraîné sur mes séries de *rendements* — pensé comme livrable autonome : c’est le volet **modélisation générative** de ce portfolio, au même titre que le RL en est le volet décisionnel. Deux garde-fous posés *avant d’écrire la moindre ligne* :

- **honnêteté sur ce qu’un générateur peut faire** : entraîné sur 2010–2019, il ne peut pas « inventer 2020 ». Il *densifie* les régimes vus (corrections 2011, 2015, 2018) et permet d’en tirer plus de variantes, notamment dans les queues — l’argument est « plus de tirages là où l’histoire est avare », pas « voir le futur » ;
- **aucun branchement RL tant que les échantillons ne passent pas une validation statistique** : entraîner un agent sur du synthétique subtilement irréaliste est le pire scénario — l’agent apprendrait des régularités qui n’existent pas, et le bug serait atroce à diagnostiquer en aval. C’est le piège n°1 du domaine, je l’ai traité comme tel.

11.1 Le protocole avant le modèle

J’ai inversé l’ordre habituel : d’abord le *juge*, ensuite le candidat. Le protocole compare quatre générateurs aux fenêtres réelles (10 015 fenêtres de 256 jours, split train RL uniquement — zéro fuite vers val/test, condition pour brancher un jour la Phase 2) : une gaussienne i.i.d. (contrôle négatif), un bootstrap i.i.d. des rendements réels (marginales parfaites par construction, clustering détruit par construction), un GARCH(1,1)- t fitté par actif (la barre classique : si mon DDPM ne fait pas mieux qu’un modèle à 4 paramètres, il ne justifie pas sa complexité), et le DDPM. Les métriques sont les faits stylisés canoniques (Cont, 2001) — kurtosis et quantiles des rendements poolés, ACF des rendements (≈ 0 : pas d’alpha gratuit), ACF de $|r|$ (positive et persistante : le *volatility clustering*, cf. ma section GARCH en annexe) — plus trois métriques orientées usage : les distributions *par fenêtre* de vol réalisée, de max drawdown et de rendement terminal (ce que l’environnement RL « verrait » d’un épisode synthétique), un **score discriminatif** façon TimeGAN (un petit GRU figé essaie de distinguer réel et synthétique ; 0,5 = indiscernable), et une métrique **anti-mémorisation** (distance de chaque échantillon à sa plus proche fenêtre réelle, comparée à la distance du réel à lui-même).

Le point méthodologique auquel je tiens : **aucun seuil arbitraire**. Chaque métrique reçoit une bande d’acceptation qui est la distribution d’échantillonnage de cette métrique *sous le réel* (200 tirages de 1 000 fenêtres réelles), et six critères d’échec É1–É6 ont été **pré-enregistrés** — écrits dans un JSON, avec leurs seuils, *avant* le premier entraînement, ainsi qu’une prédiction datée avant chaque run. É1 est le méta-critère : le réel jugé contre ses propres bandes doit passer, et chaque baseline doit échouer exactement là où sa construction l’y condamne — sinon c’est le protocole qui est faux, pas les modèles.

11.2 É1 rejette mon protocole v1 — quatre leçons avant le premier modèle

La première calibration a fait exactement ce pour quoi É1 existe : elle a invalidé mon propre protocole, quatre fois, avant qu’aucun DDPM ne soit jugé.

- **Bandes faussement étroites.** Bande de kurtosis v1 : [13,25; 15,12] — et le bootstrap, dont les marginales sont *exactes* par construction, rejeté à 12,81. Cause : mes fenêtres glissantes se chevauchent (stride 1) ; des tirages i.i.d. de fenêtres rééchantillonnent presque la même série, écrasant la variance d’échantillonnage. Remède : tirages par *runs contigus* de 256 fenêtres — chaque tirage inclut ou exclut des régimes entiers. Bande honnête : [3,7; 20,1].
- **Un juge qui apprenait l’époque, pas le réalisme.** Test de santé : opposer au juge deux moitiés entrelacées du réel — attendu $\approx 0,5$, mesuré 0,39. Mon split donnait au réel un test « fin de période » et au faux un test « toutes périodes » : le GRU classait l’époque. Remède : splits par blocs contigus tirés au hasard, purgés avec embargo autour des blocs de test (l’idée des purged splits de de Prado, ici au niveau des fenêtres). Santé v2 : 0,478. Au passage, une mesure gratuite : le juge ne distingue pas 2010–2014 de 2015–2019 (acc 0,47) — la non-stationnarité de mes données est indétectable à cette granularité.
- **Un juge bimodal.** Même configuration, trois seeds : accuracies 0,88, 0,94... et 0,50 — collapse d’optimisation occasionnel, favorisé par les rendements extrêmes ($|z|$ jusqu’à 12) qui saturent le GRU. Remède : entrées clippées à $\pm 8\sigma$ et médiane de trois entraînements. Le juge devient net : gaussienne détectée à 0,91, bootstrap à 0,89.
- **La baseline « gold standard » échoue elle-même le critère des queues.** Kurtosis des échantillons GARCH : 44,8, contre 14–15 pour le réel. Ce n’est pas un bug : le MLE donne $\hat{\nu} \in [3,8; 4,8]$ (sous 4, le quatrième moment d’une Student est *infini*), et pour AAPL ($\alpha = 0,167$, $\beta = 0,823$) la condition d’existence de la kurtosis inconditionnelle est violée même à innovations gaussiennes. J’ai donc acté : É2 du GARCH *reporté mais non exigé* (le contrôle des marginales appartient au bootstrap), GARCH exigé sur É3/É4 et comme ancre d’É5. Leçon de desk : le juge d’un backtest s’audite comme le backtest lui-même.

Calibration v2 : É1 entièrement vert, bandes et ancres **figées** — seuil É5 = accuracy GARCH +5 points = 0,682 ; seuil É6 = percentile 10 des distances NN du réel à lui-même = 6,91.

11.3 v1 : un NO-GO qui contredit ma prédiction — dans les deux sens

Prédiction pré-enregistrée avant le run v1 (U-Net 1D de 0,56M paramètres, ε -prediction, $T = 1000$, 25 000 pas, 75 min) : *les marginales passeront (É2), le point de friction sera la persistance longue de l'ACF de $|r|$ (É4) — trop dure à capturer pour un U-Net sans attention.* Le verdict mesuré a inversé mes deux paris :

Critère	Prédit	Mesuré	Chiffre
É2 queues	passé	échec	kurtosis 35,8 $\notin$ [3,7; 20,1]
É3 ACF parasite	passé	passé	lags 1–5 dans la bande
É4 clustering	échec	passé	lag 1 : 0,139 $\in$ [0,029; 0,160]
É5 discriminatif	0,60–0,75	échec	acc 0,868 $>$ 0,682
É6 mémorisation	passé	passé	méd. NN 8,21 $\geq$ 6,91

Table 11 – DDPM v1 contre les critères pré-enregistrés : NO-GO (3/5). Ma crainte principale (É4) était infondée ; le vrai défaut était ailleurs.

Le U-Net capture donc le volatility clustering — le fait stylisé que je jugeais le plus difficile. Le vrai symptôme : **écart-type généré** 0,0106 **contre** 0,0185 **pour le réel**, un rétrécissement de 43 %, *uniforme* sur toute la distribution de vol par fenêtre (chaque quantile $\approx \times 0,6$) — ce n'est pas un effondrement vers un mode, c'est une échelle globalement fausse. La kurtosis explosée en découle (elle est sans échelle : des pointes normales deviennent énormes relativement à une dispersion trop faible), et le juge discriminatif n'a plus qu'à lire le niveau moyen de $|r|$. J'ai éliminé l'EMA comme suspect (les poids bruts font *pire* : z-std 0,52).

Le mécanisme, une fois vu, est limpide et propre aux données financières : des rendements journaliers sont quasi *blancs* — le signal et le bruit de diffusion ont la même texture. Le réseau qui prédit ε sur-attribue une fraction infime du signal au bruit, et cette fraction se *compose sur les 1 000 pas* du processus inverse : un biais de 6×10^{-4} par pas suffit à produire $\times 0,55$. Sur des images, la structure spatiale protège ; sur du bruit financier, rien ne protège.

11.4 L'expérience contrôlée qui a choisi la v2

Plutôt que d'empiler des correctifs, j'ai isolé la question sur un processus dont je connais la vérité : un GARCH- t simulé (z-std vraie = 1), deux petits DDPM identiques à l'objectif près, 4 000 pas chacun. Résultat : ε -prediction $\rightarrow$ z-std 1,293 ; **v-prediction** (Salimans & Ho, 2022 : le réseau prédit $v = \sqrt{\bar{\alpha}} \varepsilon - \sqrt{1 - \bar{\alpha}} x_0$, un objectif bien conditionné à tous les niveaux de bruit) $\rightarrow$ z-std 0,945. L'instabilité d'échelle est bien un artefact de l'objectif, pas du réseau.

Configuration v2, et prédiction pré-enregistrée avant le run : v-prediction, 50 000 pas (la loss v1 descendait encore — les queues s'apprennent en dernier), décroissance cosinus du learning rate ($2 \cdot 10^{-4} \rightarrow 10^{-5}$: la calibration fine d'échelle se joue en fin d'entraînement). *Prédit : É2, É3, É4, É6 passent ; tout se joue sur É5, accuracy attendue entre 0,62 et 0,72 contre un seuil à 0,682 — GO probable mais non certain. Budget affiché : deux itérations sérieuses, puis on documente, y compris un échec.*

11.5 Verdict v2 : NO-GO — et le vrai coupable n'était aucun des deux objectifs

La v2 (50 000 pas, 3 h48) échoue sur les *mêmes* critères que la v1 :

Critère	v1 (ε -pred)	v2 (v-pred)	v2, chiffre
É2 queues	échec	échec	kurtosis 45,0 ; σ générée 0,0103 vs 0,0185
É3 ACF parasite	passe	passe	lags 1–5 dans la bande
É4 clustering	passe	passe	lag 1 : 0,143 $\in$ [0,029; 0,160] ; somme 0,93
É5 discriminatif	échec	échec	acc 0,868 (seuil 0,682)
É6 mémorisation	passe	passe	méd. NN 7,91 $\geq$ 6,91

Table 12 — v1 et v2 contre les critères pré-enregistrés. Ma prédiction v2 (« GO probable, $\sim 60\%$ ») est falsifiée — et l’indice décisif est dans la répétition : le rétrécissement de variance est $\times 0,56$ en v2 contre $\times 0,57$ en v1, *identique sous deux objectifs différents*.

Un même symptôme sous deux paramétrisations, ça ne ressemble plus à un problème d’objectif — ça ressemble à un bug de *sampling*. Avant de conclure quoi que ce soit, j’ai écrit le test qui tranche : remplacer le réseau par le débruiteur *optimal analytique* pour des données $\mathcal{N}(0,1)$ (calculable en forme fermée pour les deux objectifs) et faire tourner la boucle de génération telle quelle. Résultat : écart-type 0,9985 pour les deux — **le sampler est exact**, les deux verdicts sont valides, et ce test-oracle est resté dans ma suite de tests. Réflexe transposé du RL : quand le simulateur est soupçonnable, on ne débat pas, on l’audite.

Le vrai coupable apparaît dans la décomposition par quantile de la vol par fenêtre : le ratio généré/réel vaut $\approx 0,6$ sur presque toute la distribution, mais 0,43 au quantile 95. Le modèle sous-disperse partout ET refuse en plus de s’engager sur les fenêtres de haute volatilité. Or ma micro-expérience de contrôle (GARCH, où v-pred calibrat bien l’échelle) portait sur un processus à échelle *unique* — alors que mes données réelles sont un **mélange d’échelles** (TSLA $\approx 3\times$ SPY, régimes calmes contre crises), assumé dès le choix de la normalisation globale. Un débruiteur entraîné en espérance conditionnelle sur un mélange régresse vers le centre du mélange : il « moyenne » les échelles au lieu d’en choisir une par fenêtre. La kurtosis explosée (45) et le juge discriminatif à 0,868 sont deux lectures du même fait.




Figure 15 — Ce qui est acquis : l’ACF des rendements reste dans la bande (≈ 0 , pas d’alpha fantôme — É3), et l’ACF de $|r|$ du DDPM (rouge) est dans la bande réelle : le volatility clustering est capturé (É4), là où les deux baselines i.i.d. s’effondrent à zéro.




Figure 16 — Ce qui condamne : les distributions *par fenêtre* vues par l’environnement RL. La vol réalisée du DDPM (rouge) est décalée d’un facteur $\approx 0,6$ vers la gauche, et sa queue haute — les fenêtres de crise, précisément celles pour lesquelles ce générateur existe — est la plus atrophiée (ratio 0,43 au q95).

Budget pré-enregistré épuisé : deux itérations sérieuses, deux NO-GO — je m’arrête et je documente, comme je l’avais écrit avant de commencer. Le bilan n’est pas nul, il est précis : un protocole de validation calibré, auto-audité et réutilisable ; un générateur qui capture la structure temporelle (clustering) mais pas la structure d’échelle d’un mélange multi-actifs ; un mécanisme d’échec compris, mesuré, reproductible ; et un levier clair pour une éventuelle v3 *hors de ce budget* : retirer le mélange d’échelles du problème (normalisation par ticker, l’échelle étant réinjectée au tirage) ou le donner à contrôler au modèle (conditionnement par la vol de la fenêtre). La Phase 2 — brancher du synthétique dans le pipeline RL — reste verrouillée : c’était tout l’intérêt d’avoir écrit la règle avant les résultats.

11.6 Ce que ça ouvre

La Phase 2 — brancher le générateur dans le pipeline RL — a maintenant sa condition d’entrée écrite : des échantillons qui passent É1–É6, et un juge dont je connais les limites. Le protocole lui-même est réutilisable tel quel pour tout générateur futur (TimeGrad, conditionnement par régime pour fabriquer à *volonté* des krachs et des rebonds — la réponse directe au fold 2020). Et la règle de jugement ne change pas : tout apport du synthétique au RL se mesurera contre la bande de bruit inter-seeds et le walk-forward, pas contre un backtest unique.

12 Limites honnêtes et travaux futurs

- **Profil régime-dépendant** (section 7) : la limite principale. La piste « features de régime » a été testée et falsifiée (section 9.2) ; les pistes restantes, par ordre : position continue avec récompense sensible au régime, puis adversarial training.
- **L’alpha est majoritairement porté par la règle de stop** (section 8) : sans kill-switch, il reste +5 % (Multi) à −2 % (Single). L’agent n’a pas appris une gestion du risque continue — le MaxDD ≈ 25 % EST le seuil du stop.
- **Sharpe** < 1 : honorable pour du mono-actif avec frais, loin des standards d’un desk — le cadre sans allocation limite structurellement la diversification (Markowitz).
- **Biais de sélection des actifs** : AAPL, MSFT, GOOGL, SPY, TSLA sont des survivants à succès — biais du survivant assumé, à corriger avec un univers plus large et daté.
- **Microstructure simplifiée** : frais constants, pas de slippage ni d’impact, exécution au cours de clôture, emprunt de titres gratuit — la grille de frais de la section 8 borne partiellement ces effets (le Multi tient jusqu’à 30 bp).
- **Walk-forward simplifié** : 400k pas par fold, folds annuels, pas d’agrégation en portefeuille multi-actifs.

- **Le générateur densifie, il n’invente pas** (section 11) : entraîné sur 2010–2019, il recombine et rééchantillonne les régimes vus — il ne produira pas un COVID s’il n’en a pas vu. L’apport attendu en Phase 2 est « plus de tirages dans les queues apprises », et cette promesse-là reste à démontrer contre la bande inter-seeds.
- **Générateur univarié, tickers poolés** : un échantillon = un pseudo-actif isolé. Pas de corrélations croisées entre actifs — suffisant pour mon environnement mono-actif, insuffisant pour toute extension portefeuille.
- **Génération non conditionnelle** : je ne contrôle pas le régime généré (impossible de demander « un krach »). Le conditionnement par régime est l’extension naturelle si la Phase 2 veut un curriculum ciblé.

À plus long terme, la feuille de route du dépôt (`roadmap.md`) prévoit le multi-agents (adversaire de marché, MAPPO — section 3.4). La génération de scénarios par diffusion, elle, a désormais sa Phase 1 mesurée (section 11) ; la Phase 2 — le curriculum réel/synthétique dans le pipeline RL — ne sera lancée que sur des échantillons validés, et jugée avec le même protocole que tout le reste : bande de bruit inter-seeds et walk-forward.

13 Glossaire minute

Chaque concept en trois temps : la définition, le rôle qu’il joue *dans ce projet*, et — quand il y en a un — le piège associé. C’est ma fiche de révision d’avant-entretien.

Alpha Surperformance par rapport à une référence. Formellement, l’alpha de Jensen retranche la part du rendement expliquée par l’exposition au marché : $\alpha_J = R_p - [R_f + \beta(R_m - R_f)]$. Ici je prends $\beta = 1$ et $R_f = 0$, donc $\alpha = R_p - R_{B\&H}$: c’est à la fois ma récompense d’entraînement (par pas) et ma métrique d’évaluation (par période). Piège : un alpha ne veut rien dire sans préciser la référence ET la fenêtre — tout mon chapitre walk-forward tient dans cette remarque.

Avantage (A_t) Ce qu’une action a rapporté *au-delà* de ce que la fonction de valeur attendait de l’état : $A(s, a) = Q(s, a) - V(s)$. C’est le signal que le policy gradient renforce — pas le rendement brut, l’écart à l’attente. Estimé ici par GAE avec $\lambda = 0,95$ (annexe A.2), l’arbitrage biais/variance appliqué au gradient.

Buy & Hold (B&H) Acheter le premier jour, ne plus rien faire. La référence passive que toute stratégie active doit justifier de battre *après frais* — car le B&H, lui, ne paie qu’un seul aller. Sur mon test 2021–2022 : $-3,7\%$, avec un drawdown de 30% : battre le B&H ne veut pas dire gagner beaucoup, parfois juste perdre moins.

Coûts de friction Tout ce qui sépare un backtest du réel. *Spread* : écart entre prix acheteur et vendeur — on paie la moitié à chaque passage. *Slippage* : écart entre le prix décidé et le prix exécuté. *Impact* : mes propres ordres déplacent le prix (négligeable ici, pas en desk). *Emprunt de titres* : shorter exige d’emprunter l’action, moyennant un loyer qui peut être prohibitif sur les titres demandés. Mon simulateur résume tout en frais proportionnels — la grille de stress (section 8) teste jusqu’à 30 bp.

CVaR₉₅ / VaR₉₅ La VaR₉₅ est le quantile à 5% des rendements journaliers : le seuil de perte franchi en moyenne un jour sur vingt. La CVaR (Expected Shortfall) répond à la question suivante : *ces jours-là, combien perd-on en moyenne ?* Elle regarde *dans* la queue, pas seulement où elle commence, et elle est sous-additive (diversifier ne peut pas l’augmenter) — ce que la VaR ne garantit pas ; d’où son adoption réglementaire (FRTB).

DDPM (modèle de diffusion) Modèle génératif en deux processus : l’un, *fixe*, détruit progressivement une donnée en T pas de bruit gaussien (il n’y a rien à apprendre) ; l’autre, *appris*, inverse cette destruction pas à pas — générer = partir d’un bruit pur et débruiter T fois.

Ici : générateur de fenêtres de 256 jours de rendements (section 11), le volet IA générative du projet. Piège : sur des rendements quasi blancs, signal et bruit ont la même texture — un biais infime du débruitage se compose sur les T pas (ma v1 : variance rétrécie de 43 %).

Drawdown Perte courante depuis le dernier pic : $DD_t = (\max_{s \leq t} V_s - V_t) / \max_{s \leq t} V_s$. Le *max drawdown* en est le pire cas sur la période. C'est le risque « vécu » : un investisseur ne ressent pas une variance, il ressent -25% depuis le plus haut. Mon kill-switch est défini dessus, et le Calmar rapporte le rendement à lui.

Early stopping Conserver la version du modèle la meilleure *en validation* plutôt que la dernière. C'est une régularisation : si la fin de l'entraînement sur-apprend le train, on ne la paie pas. Corollaire qui m'a coûté cher : la qualité de cette sélection vaut celle du signal de validation (tableau 3 : +30 points d'alpha entre une validation corrompue et une propre, tout le reste identique).

Efficience des marchés (EMH) Hypothèse de Fama (1970) en trois formes selon l'information réputée déjà « dans les prix » : *faible* (les prix passés), *semi-forte* (toute information publique), *forte* (toute information, y compris privée). Mon agent ne consommant que des prix passés, ce projet teste la forme faible — et conclut à un edge modeste, défensif et régime-dépendant : une violation limite, pas une réfutation.

EMA (des poids) Moyenne mobile exponentielle des paramètres du réseau, maintenue en parallèle de l'entraînement ($\theta_{\text{EMA}} \leftarrow 0,999 \theta_{\text{EMA}} + 0,001 \theta$). C'est *elle* qu'on évalue : les poids instantanés vibrent avec les derniers minibatches, la moyenne lissée échantillonne mieux — standard dans la littérature diffusion. À ne pas confondre avec l'early stopping : l'EMA lisse, elle ne sélectionne pas.

Entropie (bonus d') $\mathcal{H}[\pi] = -\sum_a \pi(a) \log \pi(a)$, maximale quand la politique hésite uniformément. Un petit bonus ($c_2 = 0,05$) récompense cette hésitation résiduelle $\rightarrow$ l'agent continue d'explorer au lieu de se figer prématurément sur « toujours Hold » ou « toujours Long ». Trop d'entropie : l'agent ne converge jamais ; pas assez : il converge sur la première stratégie passable.

Épisode Une traversée de la simulation, du point de départ jusqu'à la fin des données (*truncated*) ou au déclenchement d'un stop (*terminated*). À l'entraînement, les départs sont aléatoires pour varier l'expérience ; à l'évaluation de référence, le départ est fixe.

Épisode déterministe (full-split) Départ fixe + politique déterministe (l'action la plus probable, sans tirage) : deux exécutions donnent exactement le même résultat, au centime. C'est mon évaluation de référence — la version « fenêtres aléatoires » ne sert plus qu'à mesurer la robustesse au point d'entrée.

Faits stylisés Les régularités statistiques universelles des rendements financiers (Cont, 2001) : queues épaisses (kurtosis $\gg 0$), autocorrélation des rendements ≈ 0 (sinon alpha gratuit), autocorrélation de $|r|$ positive et persistante (volatility clustering), asymétrie gain/perte. Ce sont les axes de mon protocole de validation des scénarios synthétiques : un générateur qui les viole fabriquerait un marché qui n'existe pas.

Fonction de valeur $V(s)$ L'estimation, par le critique, de ce qu'un état rapportera en moyenne sous la politique courante. C'est l'« attente » dont l'avantage mesure l'écart, et la baseline qui réduit la variance du gradient sans le biaiser (annexe A.1).

Kill-switch Arrêt de l'épisode si le drawdown dépasse 25 % — l'équivalent d'un stop-loss de mandat institutionnel. Mon ablation (section 8) montre qu'il porte ≈ 21 points de mon alpha 2022 : c'est une décision de *design* de la stratégie, pas un détail d'implémentation, et je dois le dire quand je présente mes chiffres.

Look-ahead bias Utiliser à la date t une information indisponible en t . Les formes sournoises : normaliser avec des statistiques calculées sur tout l'échantillon, sélectionner les actifs a

posteriori (survivants), choisir ses hyperparamètres en regardant le test. Le péché capital du backtesting — verrouillé ici par des tests unitaires sur le scaler et des splits strictement chronologiques.

MDP Processus de décision markovien : état $\rightarrow$ action $\rightarrow$ récompense $\rightarrow$ état suivant, avec la propriété que l'état résume tout le passé utile. Les marchés violent cette propriété (10 jours de features ne résument pas un régime) — l'hypothèse est une approximation de travail, et sa violation est exactement mon « underfitting de représentation ».

Out-of-sample Évalué sur des données jamais utilisées ni pour entraîner, ni pour choisir le modèle ou ses hyperparamètres. Le seul chiffre qui compte, et la hiérarchie est stricte : train < validation < test < walk-forward (une *séquence* de tests).

Overfitting / underfitting Apprendre par cœur le train (excellent in-sample, mauvais out-of-sample) / ne pas capter le signal disponible (mauvais partout). Mon train à +16 500 % d'alpha crie l'overfitting de mémorisation ; mon plafond réel tient au régime — et l'Acte 3 a affiné le diagnostic : donner l'information de régime ne suffit pas (section 9.2), c'est la *récompense* qui doit inciter à s'en servir.

Point de base (bp) 0,01 %. L'unité standard des coûts d'exécution et des écarts de taux : dire « 10 bp par trade » est plus précis et plus professionnel que « 0,1 % ».

Policy gradient / PPO Optimiser directement la politique par montée de gradient sur l'avantage, sans passer par une table de valeurs. PPO y ajoute le clipping du ratio ρ_t dans $[1 - \varepsilon, 1 + \varepsilon]$: aucune mise à jour ne peut trop déplacer la politique, quel que soit le lot d'expérience — la stabilité avant la vitesse, indispensable sur données bruitées (perte complète en annexe A.3).

Purged split (embargo) Découpage train/test pour données qui se *chevauchent* (mes fenêtres glissantes) : blocs contigus tirés au hasard, et on écarte du train tout ce qui touche un bloc de test à moins d'une fenêtre (l'embargo, à la de Prado). Sans lui, deux pièges symétriques : le split aléatoire fuit (fenêtres à un jour d'écart des deux côtés), le split « fin de période en test » fait apprendre l'époque au lieu du phénomène — mon juge discriminatif est tombé dans le second (acc 0,39 sur un test qui devait donner 0,5).

Score discriminatif Métrique de réalisme façon TimeGAN : un petit classifieur *figé à l'avance* apprend à distinguer fenêtres réelles et synthétiques ; accuracy 0,5 = indiscernables. Le mien détecte la gaussienne i.i.d. à 0,91 et le GARCH fitté à 0,63 — ce dernier chiffre sert d'ancre : un générateur appris doit faire au moins aussi bien qu'un modèle à 4 paramètres. Piège : un juge plus gros trouve toujours quelque chose — le seuil n'a de sens que juge constant.

Seed Graine du générateur pseudo-aléatoire. La fixer rend l'expérience exactement reproductible (comparer deux versions du code à hasard identique) ; la faire *varier* mesure la sensibilité au hasard — mesurée à l'Acte 3 : ± 21 points d'alpha sur un actif isolé, $\pm 6,5$ sur la moyenne cross-actifs. Toute amélioration se juge contre cette bande.

Sharpe / Sortino / Calmar Trois façons de rapporter le rendement au risque : à la volatilité totale ($\bar{r}/\hat{\sigma} \times \sqrt{252}$ — les 252 jours de bourse annualisent), à la volatilité *baissière* seule (Sortino ne pénalise pas les bonnes surprises), au max drawdown (Calmar). Un desk regarde les trois : un bon Sharpe avec un Calmar médiocre signale des pertes concentrées.

v-prediction Reparamétrisation de l'objectif de diffusion (Salimans & Ho, 2022) : au lieu du bruit ε , le réseau prédit $v = \sqrt{\alpha} \varepsilon - \sqrt{1 - \alpha} x_0$ — un mélange qui pivote continûment de « prédire le bruit » (faible bruit) à « prédire la donnée » (fort bruit). Mieux conditionné à tous les niveaux de bruit ; sur mes rendements quasi blancs, c'est ce qui a corrigé le rétrécissement de variance de l' ε -prediction (mesuré sur GARCH contrôlé : z-std 1,293 $\rightarrow$ 0,945).

VecNormalize Standardisation *glissante* des observations pendant l'entraînement (moyenne et variance mises à jour en continu). Ses statistiques font partie du modèle : les recharger à

l'évaluation est obligatoire — prédire sur observations brutes fut le bug le plus répété de ce projet (deux scripts touchés).

Walk-forward Réentraîner en ne voyant que le passé, tester sur la période suivante, avancer, répéter. Transforme *un* backtest en *distribution* de résultats out-of-sample — et c'est cette distribution qui a requalifié mon +27,5 % en profil défensif régime-dépendant (médiane -2 %, 48 % de cellules positives).

14 Reproduire les résultats

- Entraînement complet : `python train.py` (~10–15 min CPU);
- Rapport d'évaluation : `python evaluate.py`;
- Walk-forward : `python walk_forward.py` (~25 min, 5 folds);
- Diffusion — calibration du protocole puis entraînement puis verdict : `python validate_diffusion.py --calibration-only`, puis `python train_diffusion.py` (~75 min MPS en v1), puis `python validate_diffusion.py --model-dir models/diffusion_v2` (~20 min; bandes réutilisées telles quelles — contrat de pré-enregistrement);
- Suite de tests : `python -m pytest` (101 tests; marqueurs `network` et `slow` pour l'intégration);
- Figures de ce rapport + dashboard statique : `python reports/build_assets.py`;
- Dashboard interactif : `streamlit run dashboard.py`.

Avertissement : projet strictement éducatif. Rien ici ne constitue un conseil d'investissement; les performances simulées ne préjugent de rien.

A Annexe mathématique

Cette annexe déroule les mathématiques que le corps du rapport résume. Rien ici n'est nécessaire pour utiliser le projet; tout est utile pour le *défendre*.

A.1 Du policy gradient à l'avantage

On cherche les paramètres θ du réseau qui maximisent le rendement espéré $J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [\sum_t \gamma^t r_t]$, où τ est une trajectoire (un épisode). Le *théorème du policy gradient* donne :

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) Q^\pi(s_t, a_t) \right],$$

où $Q^\pi(s, a)$ est la valeur d'une action dans un état. L'astuce de dérivation — dite du *ratio de vraisemblance* — parlera à un économètre : c'est la même identité $\nabla p = p \nabla \log p$ qui fait apparaître le score dans le maximum de vraisemblance. Intuition : on augmente la log-probabilité des actions proportionnellement à ce qu'elles ont rapporté.

Problème : Q est estimé par des rendements réalisés, extrêmement bruités en finance $\Rightarrow$ variance énorme du gradient. Remède : soustraire une *baseline* $b(s_t)$ qui ne dépend pas de l'action. Ce retranchement ne biaise pas le gradient car

$$\mathbb{E}_{a \sim \pi} [\nabla_\theta \log \pi_\theta(a | s) b(s)] = b(s) \nabla_\theta \underbrace{\sum_a \pi_\theta(a | s)}_{=1} = 0.$$

Le choix optimal en pratique est $b(s) = V^\pi(s)$ (la fonction de valeur), ce qui fait apparaître l'**avantage** :

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad : \text{ce que l'action a rapporté } \textit{au-delà} \text{ de l'attente de l'état.}$$

A.2 Estimation de l'avantage : GAE

Comment estimer A_t ? Deux extrêmes : le résidu de différence temporelle $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ (peu de variance, mais biaisé si V est mal estimée) ou le rendement Monte-Carlo complet (sans biais, variance maximale). GAE (*Generalized Advantage Estimation*) interpole entre les deux par une somme géométrique de résidus :

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}, \quad \lambda \in [0, 1].$$

$\lambda = 0$ redonne δ_t (tout biais), $\lambda = 1$ le Monte-Carlo (toute variance). J'utilise la valeur standard $\lambda = 0,95$: sur des rendements financiers, accepter un peu de biais pour beaucoup moins de variance est le bon échange — exactement l'arbitrage biais/variance du cours d'économétrie, appliqué à l'estimation d'un gradient.

A.3 La perte PPO complète

Ce que Stable-Baselines3 minimise réellement est la somme de trois termes :

$$\mathcal{L}(\theta) = \underbrace{-\mathbb{E}_t \left[\min(\rho_t A_t, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) A_t) \right]}_{\text{politique (clippée)}} + c_1 \underbrace{\mathbb{E}_t [(V_\theta(s_t) - V_t^{\text{cible}})^2]}_{\text{valeur}} - c_2 \underbrace{\mathbb{E}_t [\mathcal{H}[\pi_\theta(\cdot | s_t)]]}_{\text{entropie}},$$

avec ici $\varepsilon = 0,15$, $c_1 = 0,5$, $c_2 = 0,05$ et $\rho_t = \pi_\theta(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$.

Trois lectures :

- le **min** rend l'objectif *pessimiste* : si le ratio ρ_t sort de $[1 - \varepsilon, 1 + \varepsilon]$ dans le sens qui augmenterait l'objectif, le gradient est coupé — on ne « surexploite » jamais un lot d'expérience ;
- le terme de **valeur** entraîne le critique — V_t^{cible} est le rendement observé « bootstrappé » *au sens RL* : au-delà de l'horizon collecté, on complète par l'estimation $V(s_{t+n})$ elle-même (rien à voir avec le bootstrap par rééchantillonnage de l'économétrie : ici on s'appuie sur sa propre estimation, là-bas on rééchantillonne ses données) ; sans bon critique, pas de bon avantage ;
- l'**entropie** $\mathcal{H}[\pi] = -\sum_a \pi(a) \log \pi(a)$ est maximale pour une politique uniforme : la pénaliser négativement ($-c_2 \mathcal{H}$ dans la perte) revient à *récompenser* l'indécision résiduelle, donc l'exploration.

A.4 Le processus d'Ornstein-Uhlenbeck en détail

L'équation $dX_t = \kappa(\mu - X_t) dt + \sigma dW_t$ se résout explicitement (par la méthode du facteur intégrant $e^{\kappa t}$, comme une EDO linéaire) :

$$X_t = \mu + (X_0 - \mu) e^{-\kappa t} + \sigma \int_0^t e^{-\kappa(t-s)} dW_s.$$

Lectures immédiates :

- **Espérance** : $\mathbb{E}[X_t] = \mu + (X_0 - \mu) e^{-\kappa t}$ — l'écart initial fond exponentiellement ; la *demi-vie* $t_{1/2} = \ln 2 / \kappa$ est le temps pour en effacer la moitié.
- **Variance stationnaire** : $\text{Var}[X_\infty] = \sigma^2 / (2\kappa)$ — le processus fluctue d'autant plus large que le rappel est faible.
- **Discrétisation exacte** au pas Δ :

$$X_{t+\Delta} = \mu (1 - \varphi) + \varphi X_t + \varepsilon_t, \quad \varphi = e^{-\kappa \Delta}, \quad \varepsilon_t \sim \mathcal{N}\left(0, \frac{\sigma^2}{2\kappa} (1 - \varphi^2)\right).$$

C'est un **AR(1)** : le pont exact entre calcul stochastique et économétrie. Estimation : une MCO de $X_{t+\Delta}$ sur X_t donne $\hat{\varphi}$, d'où $\hat{\kappa} = -\ln \hat{\varphi}/\Delta$ et la demi-vie. (Tester $\varphi = 1$ contre $\varphi < 1$, c'est exactement le test de racine unitaire de Dickey-Fuller : un OU est l'alternative stationnaire.)

Usage type en trading : modéliser le *spread* de deux actifs cointégrés, estimer κ et $t_{1/2}$, n'entrer que si la demi-vie est courte devant l'horizon de détention et les frais — le cœur du projet stat-arb décrit dans PROJETS_FUTURS.md.

B Compléments théoriques : les ponts avec mes cours

Cette annexe développe les quatre corps de théorie que le rapport mobilise sans les dérouler. Elle est écrite pour relier explicitement le projet à ce que j'ai vu en licence d'économie (gestion de portefeuille, économétrie) et en calcul stochastique.

B.1 CAPM et alpha de Jensen : d'où vient ma récompense

Le *Capital Asset Pricing Model* (Sharpe, Lintner, 1964) postule qu'à l'équilibre, le rendement espéré d'un actif ne dépend que de son exposition au risque de marché :

$$\mathbb{E}[R_i] = R_f + \beta_i (\mathbb{E}[R_m] - R_f), \quad \beta_i = \frac{\text{Cov}(R_i, R_m)}{\text{Var}(R_m)}.$$

Cette droite — la *Security Market Line* — dit ce qu'un actif « devrait » rapporter vu son β . L'**alpha de Jensen** est l'écart empirique à cette prédiction :

$$\alpha_i = \mathbb{E}[R_i] - [R_f + \beta_i(\mathbb{E}[R_m] - R_f)].$$

Un $\alpha > 0$ est une performance *inexpliquée* par l'exposition au marché — le Graal du gérant actif. Ma récompense par pas (section 4) est cet α sous les hypothèses simplificatrices $\beta = 1$ et $R_f = 0$: je récompense l'agent pour ce que le marché seul n'explique pas. En pratique, mesurer un « vrai » alpha exigerait d'estimer β par la régression $R_{i,t} - R_f = \alpha_i + \beta_i(R_{m,t} - R_f) + \varepsilon_t$ — une régression MCO où l'intercept *est* l'alpha : le pont le plus direct entre mon cours d'économétrie et ma métrique.

B.2 Markowitz, frontière efficiente et ratio de Sharpe

La théorie moderne du portefeuille (Markowitz, 1952) pose le problème de l'allocation comme un arbitrage moyenne-variance : pour un vecteur de poids w , rendement espéré $w^\top \mu$ et risque $w^\top \Sigma w$. L'ensemble des portefeuilles qui maximisent le rendement à risque donné forme la **frontière efficiente** (figure 17).




Figure 17 — Nuage de portefeuilles simulés sur quatre actifs. Le bord supérieur-gauche est la frontière efficiente; l'étoile est le portefeuille de *Sharpe maximal*, point de tangence de la *Capital Market Line* issue de r_f . Le ratio de Sharpe est géométriquement la *pente* de la droite reliant r_f à un portefeuille : le maximiser, c'est trouver la droite la plus raide qui touche encore le nuage.

Deux idées de ce cadre irriguent le projet. D'abord, le **ratio de Sharpe** que j'utilise comme métrique n'est pas un choix arbitraire : c'est la pente de la CML, l'unité naturelle du « rendement par unité de risque » dans ce modèle. Ensuite, la **diversification** : parce que les actifs sont imparfaitement corrélés (Σ n'est pas diagonale), un portefeuille a moins de risque que la moyenne de ses composantes — la seule « free lunch » de la finance. C'est exactement le mécanisme que je retrouve, de façon inattendue, dans la robustesse au seed (section 9.1) : moyenner l'alpha sur cinq actifs diversifie le bruit d'entraînement idiosyncratique, comme un portefeuille diversifie le risque spécifique. Mon environnement, lui, reste mono-actif (pas d'allocation) — d'où un Sharpe structurellement plafonné, et le projet « allocation sous contrainte CVaR » de ma liste.

B.3 GARCH : modéliser le regroupement de volatilité

Les rendements financiers ne sont pas homoscédastiques : leur variance change dans le temps et se regroupe (figure 6). Le modèle GARCH(1,1) (Bollerslev, 1986, généralisant l'ARCH d'Engle, 1982) capture ce fait par une variance conditionnelle autorégressive :

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \mathcal{N}(0, 1).$$

La variance de demain est un mélange d'un socle ω , du choc d'hier ε_{t-1}^2 (terme ARCH) et de la variance d'hier σ_{t-1}^2 (terme GARCH). La condition de stationnarité $\alpha + \beta < 1$ garantit un retour vers la variance de long terme $\omega/(1 - \alpha - \beta)$; en pratique sur actions, $\alpha + \beta$ est proche de 1 (volatilité très persistante). Je n'estime pas de GARCH dans ce projet — ma feature **volatility** en est un proxy non paramétrique (l'écart-type glissant) — mais c'est le modèle de référence auquel je comparerais une prévision de volatilité (projet « GARCH vs ML » de ma liste), et le vocabulaire attendu dès qu'on parle de risque conditionnel.

B.4 Équation de Bellman : le socle de la fonction de valeur

Pourquoi la fonction de valeur $V(s)$ (le critique de PPO) est-elle apprenable ? Parce qu'elle satisfait une relation de cohérence récursive, l'**équation de Bellman** :

$$V^\pi(s) = \mathbb{E}_{a \sim \pi, s'} [r(s, a) + \gamma V^\pi(s')].$$

« La valeur d'aujourd'hui = récompense immédiate + valeur actualisée de demain. » C'est le principe d'optimalité de la programmation dynamique (Bellman, 1957) — le même qui sous-tend la résolution récursive d'un arbre de décision ou le pricing d'une option américaine par backward induction. Le critique apprend V en réduisant l'écart entre ses deux membres (l'erreur de différence temporelle $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$, brique de GAE en annexe A.2). Le pont avec la finance quantitative est direct : évaluer une option américaine, c'est résoudre une équation de Bellman où « exercer » est une action et la valeur de continuation joue le rôle de $\gamma V(s')$.